

1 Zadanie 1

Opis problemu: W zadaniu należało wyznaczyć następujące wartości:

- *Macheps* — najmniejsza liczba *macheps* > 0 taka, że $f(1.0 + \text{macheps}) > 1.0$ i $f(1.0 + \text{macheps}) = 1 + \text{macheps}$
- *eta* — najmniejsza dodatnia liczba zmiennoprzecinkowa (najmniejsza liczba nieznormalizowana — MIN_{sub})
- liczba *MAX* — największa liczba nieznormalizowana — MAX_{sub}

Oraz odpowiedzieć na pytania:

- Jaki związek ma liczba *macheps* z *precyzją arytmetyki* (oznaczaną na wykładzie przez ϵ)?
- Jaki związek ma liczba *eta* z liczbą MIN_{sub} ?
- Co zwracają funkcje `floatmin(Float32)` i `floatmin(Float64)` i jaki jest związek zwracanych wartości z liczbą MIN_{nor} ?

Wyniki:

1.1 *Macheps*

1.1.1 **Float64**

`eps(Float64)` = 2.220446049250313e-16

Mój wynik: 2.220446049250313e-16

1.1.2 **Float32**

`eps(Float32)` = 1.1920929e-07

Mój wynik: 1.1920929e-07

1.1.3 **Float16**

`eps(Float16)` = 0.000977

Mój wynik: 0.0009765625

1.2 *eta*

1.2.1 **Float64**

`nextfloat(Float64(0.0))` = 5.0e-324

Mój wynik: 5.0e-324

1.2.2 **Float32**

`nextfloat(Float32(0.0)) = 1.0e-45`
Mój wynik: 1.0e-45

1.2.3 **Float16**

`nextfloat(Float16(0.0)) = 6.0e-8`
Mój wynik: 6.0e-8

1.3 *MAX*

1.3.1 **Float64**

`floatmax(Float64(0.0)) = 1.7976931348623157e308`
Mój wynik: 1.7976931348623157e308

1.3.2 **Float32**

`floatmax(Float32(0.0)) = 3.4028235e38`
Mój wynik: 3.4028235e38

1.3.3 **Float16**

`floatmax(Float16(0.0)) = 6.55e4`
Mój wynik: 6.55e4

1.4 Wartości z float.h:

1.4.1 **FLOAT**

`FLT_MAX = 3.4028234664e+38`
`FLT_MIN = 1.1754943508e-38`
`FLT_EPSILON = 1.1920928955e-07`

1.4.2 **DOUBLE**

`DBL_MAX = 1.79769313486231570815e+308`
`DBL_MIN = 2.22507385850720138309e-308`
`DBL_EPSILON = 2.22044604925031308085e-16`

1.4.3 LONG DOUBLE

```
LDBL_MAX = 1.189731495357231765021263853031e+4932
LDBL_MIN = 3.362103143112093506262677817322e-4932
LDBL_EPSILON = 1.084202172485504434007452800870e-19
```

1.5 Odpowiedzi na pytania:

1. Jaki związek ma liczba *macheps* z precyją arytmetyki (oznaczaną na wykładzie przez ϵ)?
Precyza arytmetyki $\epsilon = 0.5\beta^{1-t}$ ($\text{macheps} = \beta^{1-t}$). Wynika to z tego, że błąd musi spełniać założenie $|\delta| \leq \epsilon$ i $\text{fl}(1.0 + \delta) = 1.0$. Oznacza to, że nie może zostać zaokrąglony w górę, ponieważ wtedy będzie już następną liczbą.
2. Jaki związek ma liczba *eta* z liczbą MIN_{sub} ?
$$\text{Min}_{\text{sub}} = m_{\min} * \beta^{c_{\min}} = \beta^{1-t} * \beta^{c_{\min}} = \beta^{c_{\min} + (1-t)}$$
$$\text{MIN}_{\text{nor}} = 1 * \beta^{c_{\min}}$$
$$\text{Liczba eta} = \text{Min}_{\text{sub}}$$
3. Co zwracają funkcje `floatmin(Float32)` i `floatmin(Float64)` i jaki jest związek zwracanych wartości z liczbą MIN_{nor} ?
`Floatmin` jest MIN_{nor} dla danych typów

1.6 Wnioski

Wyniki uzyskane w zadaniu są zgodne z wartościami podanymi w języku. Zauważamy, że `eps()` oznacza najmniejszą różnicę między liczbami w zakresie mantysy, a `nextfloat()` zwraca najmniejszą możliwą następną liczbę.

2 Zadanie 2

Opis problemu: W zadanie trzeba było sprawdzić, czy wynik równania $3(\frac{4}{3} - 1) - 1$ zwraca wartości epsilon maszynowego

Wyniki:

2.1 Float64

`eps(Float64)` = 2.220446049250313e-16
Wynik równania: -2.220446049250313e-16

2.2 Float32

`eps(Float32)` = 1.1920929e-07
Wynik równania: 1.1920929e-07

2.3 Float16

eps(Float16) = 0.000977
Wynik równania: -0.000977

2.4 Wnioski

Wyniki uzyskane w zadaniu są zgodne z wartościami $\text{eps}()$ dla danych typów. Wynika to z faktu, że w obliczeniach występują błędy zaokrągleń, które powodują, że wynik jest równy $\text{eps}()$ lub jego przeciwnemu.

3 Zadanie 3

Opis problemu: W zadaniu należało zbadać odległości między liczbami w arytmetyce zmiennoprzecinkowej w różnych przedziałach. Należało sprawdzić, czy liczba 2^{-52} jest taka odległość.

Wyniki:

3.1 Przedział [1,2]

2^{-52} jest odlegością między kolejnymi liczbami w tym przedziale. Możemy stwierdzić to na podstawie binarnego zapisu tych liczb.

Różnią się one na ostatnim bicie, co oznacza, że 2^{-52} jest odległością między tymi liczbami.

3.2 Przedział [2,4]

W tym przedziale odległość między kolejnymi liczbami wynosi 2^{-51} . Możemy stwierdzić to na podstawie binarnego zapisu tych liczb.

Jak widać dodanie 2^{-52} do liczby 2 nie zmienia jej wartości, co oznacza, że 2^{-52}

Jak widać dodanie 2^{-50} do liczby 2 nie zmienia jej wartości, co oznacza, że 2 mniejsze od odległości między tymi liczbami. Natomiast dodając 2^{-51} do liczby 2 otrzymujemy otrzymujemy następną liczbę w tym przedziale.

3.3 Przedział $[\frac{1}{2}, 1]$

Różnią się one na przedostatnim biecie, co oznacza, że 2^{-52} jest dwukrotnie większa od odległości między tymi liczbami.

3.4 Wnioski

W zadaniu udało się potwierdzić, że odległości między liczbami w arytmetyce zmiennoprzecinkowej zależą od przedziału, w którym się znajdują. W przedziale $[1,2]$ odległość ta wynosi 2^{-52} , w przedziale $[2,4]$ wynosi 2^{-51} , a w przedziale $[\frac{1}{2},1]$ wynosi 2^{-53} .

4 Zadanie 4

Opis problemu:

W zadaniu należało znaleźć taką liczbę zmiennoprzecinkową $x \in (1, 2)$, dla której $x * (\frac{1}{x}) \neq 1$. Należało również znaleźć najmniejszą taką liczbę.

4.1 Wynik

Liczba 1.000000057228997 jest najmniejszą liczbą spełniającą warunki zadania.

4.2 Wnioski

W x odległość między liczbami wynosi 2^{-52} , ale w $\frac{1}{x}$ to już jest 2^{-53} (Ponieważ $\frac{1}{x} \in (\frac{1}{x}, 1)$). Wychodzi na to, że musi to być liczba, która przy dzieleniu jedynki zostanie zaokrąglona w góre oraz później przy mnożeniu przez siebie nie zostanie zaokrąglona w dół.

5 Zadanie 5

Opis problemu:

W zadaniu należało zaimplementować funkcje obliczające iloczyn skalarny dwóch wektorów.

Wyniki:

5.1 Float64

- a) Wynik: 1.0251881368296672e-10
- b) Wynik: -1.5643308870494366e-10
- c) Wynik: 0.0
- d) Wynik: 0.0

5.2 Float32

- a) Wynik: -0.4999443
- b) Wynik: -0.4543457
- c) Wynik: -0.5
- d) Wynik: -0.5

5.3 Wnioski

W zadaniu nie udało się zbytnio zaobserwować wpływu redukcji liczb znaczących na wynik, ponieważ przypadki, gdzie dane były posortowane dały nam takie same wyniki. Zauważać na pewno można jednak, że kolejność dodawania ma znaczenie, ponieważ dodawanie "od przodu" i "od tyłu" dały różne wyniki. Kierując się informacjami z wykładu wiemy, że redukcja cyfr znaczących występuje w momencie dodawania liczb skrajnie mniejszych do większych. Natomiast w przypadku odejmowania redukcja ta nachodzi przy liczbach bardzo do siebie zbliżonych.

Poprawny wynik: $-1.00657107000000 * 10^{-11}$

Najbliżej poprawnego wyniku była metoda b) dla Float64, czyli dodawanie "od tyłu".

6 Zadanie 6

Opis problemu:

W zadaniu należało zaimplementować dwie funkcje i porównać ich wyniki dla różnych wartości n.

Funkcje:

- $f(n) = \sqrt{x^2 + 1} - 1$
- $g(n) = \frac{x^2}{\sqrt{x^2 + 1} + 1}$

6.1 Wyniki

f(0.125)= 0.0077822185373186414
g(0.125)= 0.0077822185373187065
f(0.015625)= 0.00012206286282867573
g(0.015625)= 0.00012206286282875901
f(0.001953125)= 1.9073468138230965e-6
g(0.001953125)= 1.907346813826566e-6
f(0.000244140625)= 2.9802321943606103e-8
g(0.000244140625)= 2.9802321943606116e-8
f(3.0517578125e-5)= 4.656612873077393e-10
g(3.0517578125e-5)= 4.6566128719931904e-10

```
f(3.814697265625e-6)= 7.275957614183426e-12
g(3.814697265625e-6)= 7.275957614156956e-12
f(4.76837158203125e-7)= 1.1368683772161603e-13
g(4.76837158203125e-7)= 1.1368683772160957e-13
f(5.960464477539063e-8)= 1.7763568394002505e-15
g(5.960464477539063e-8)= 1.7763568394002489e-15
f(7.450580596923828e-9)= 0.0
g(7.450580596923828e-9)= 2.7755575615628914e-17
f(9.313225746154785e-10)= 0.0
g(9.313225746154785e-10)= 4.336808689942018e-19
```

6.2 Wnioski

Wyniki funkcji f i g są zbliżone dla większych wartości n, ale wraz ze zmniejszaniem się n, różnice między nimi rosną. Dla bardzo małych wartości n, funkcja f zwraca 0, podczas gdy funkcja g nadal zwraca wartości bliskie zeru, ale niezerowe. Wynika to z faktu, że w odejmowaniu w funkcji f następuje redukcja cyfr znaczących. Wynika to z faktu, że $\sqrt{x^2 + 1}$ wraz ze wzrostem x zbliża się do 1, co powoduje, że różnica między nimi staje się bardzo mała i prowadzi do utraty precyzji.

7 Zadanie 7


Opis problemu:

W zadaniu należało zaimplementować funkcję obliczającą wartość pochodnej funkcji $f(x) = \sin(x) + \cos(3x)$ w punkcie $x_0 = 1$ za pomocą wzoru $f'(x_0) = \frac{f(x_0+h) - f(x_0)}{h}$ oraz wzory pochodnej $f'(x) = \cos(x) - 3\sin(3x)$


7.1 Wyniki

7.2 Wnioski

W zadaniu udało się zaobserwować, jak wartość h wpływa na błąd przybliżenia pochodnej. Dla dużych wartości h błąd jest duży, ponieważ przybliżenie jest niedokładne. Wraz ze zmniejszaniem się h, błąd maleje, aż do pewnego momentu, gdzie zaczyna rosnąć ponownie. Dzieje się tak, ponieważ dla bardzo małych wartości h, różnica $f(x_0+h) - f(x_0)$ staje się bardzo mała i prowadzi do redukcji cyfr znaczących. Dodatkowo, na drugim wykresie widać, że dla bardzo małych wartości h, wartość $1 + h$ jest równa 1, co również wskazuje na utratę precyzji.



Rysunek 1: Błąd przybliżenia pochodnej



Rysunek 2: Wartość $1 + h$